

# 浙江大学

## 计算机视觉作业报告

作业名称：实现 LeNet-5

姓 名：陈润健

学 号：3160103989

电子邮箱：3160103989@zju.edu.cn

联系电话：18868104871

导 师：潘纲



2019 年 1 月 8 日

# 实现 LeNet-5

## 一、 作业已实现的功能简述及运行简要说明

1. 实现 LeNet-5。
2. 用 MNIST 的训练数据训练，测试数据进行测试，得到准确率。
3. 自己手写 100 个数字，用训练好的网络进行识别，得到准确率。

## 二、 作业的开发与运行环境

IDE: Xcode 10.1

操作系统: MacOS 10.14.1

SDK: macosx10.14

## 三、 基本思路，用到的函数及流程

1. LeNet-5 的原理：


- 1) 网络中各个部分的介绍：

- a) 卷积层 (Conv)：

卷积运算的目的是提取输入的不同特征，第一层卷积层可能只能提取一些低级的特征如边缘、线条和角等层级，更多层的网络能从低级特征中迭代提取更复杂的特征。

卷积层采用的都是  $5 \times 5$  大小的卷积核，且卷积核每次滑动一个像素，一个特征图谱使用同一个卷积核。

每个上层节点的值乘以连接上的参数，把这些乘积及一个偏置参数相加得到一个和，把该和输入激活函数，激活函数的输出即是下一层节点的值。



图示

b) 降采样层（池化层，pooling）：


作用是降低图片的分辨率。

降采样在  $2 \times 2$  的小方块中实现，有两种降采样的方法：平均降采样法，最大值降采样法。

平均值降采样法：将  $2 \times 2$  的方块中的平均值作为降采样之后的值。

最大值降采样法：将  $2 \times 2$  的方块中的最大值作为降采样之后的值。

下抽样层采用的是  $2 \times 2$  的输入域，即上一层的 4 个节点作为下一层 1 个节点的输入，且输入域不重叠，即每次滑动 2 个像素



c) 全连接层：

跟普通的神经网络一样的连接，位于最后几层。

2) 网络结构：一共 7 层，包括两个卷积层，两个降采样层，三个全连接层。




Fig. 2. Architecture of LeNet-5, a Convolutional Neural Network, here for digits recognition. Each plane is a feature map, i.e. a set of units whose weights are constrained to be identical.

a) 卷积层 C1：输入为  $32 \times 32$  的图像，输出为卷积得到的 6 张  $28 \times 28$  的图像。因此卷积核的大小是  $5 \times 5$ ，每个特征图谱内参数共享，

即每个特征图谱内只使用一个共同卷积核，卷积核有  $5 \times 5$  个连接参数加上 1 个偏置共 26 个参数。C1 层共有  $26 \times 6 = 156$  个训练参数。

- b) 池化层 S2: C1 层的 6 个  $28 \times 28$  的特征图谱分别进行以  $2 \times 2$  为单位的下抽样得到 6 个  $14 \times 14$  的图。
  - c) 卷积层 C3: 卷积核和 C1 相同，不同的是 C3 的每个节点与 S2 中的多个图相连。C3 层输出有 16 个  $10 \times 10$  的图。该层有
 
$$(5 \times 5 \times 3 + 1) \times 6 + (5 \times 5 \times 4 + 1) \times 3 + (5 \times 5 \times 4 + 1) \times 6 + (5 \times 5 \times 6 + 1) \times 1 = 1516$$
 个训练参数。
  - d) 池化层 S4: S4 是一个下采样层。C3 层的 16 个  $10 \times 10$  的图分别进行以  $2 \times 2$  为单位的下抽样得到 16 个  $5 \times 5$  的图。
  - e) 全连接层 C5: 由于 S4 层的 16 个图的大小为  $5 \times 5$ ，与卷积核的大小相同，所以卷积后形成的图的大小为  $1 \times 1$ 。这里形成 120 个卷积结果。每个都与上一层的 16 个图相连。所以共有
 
$$(5 \times 5 \times 16 + 1) \times 120 = 48120$$
 个参数
  - f) 全连接层 F6: F6 层有 84 个节点，对应于一个  $7 \times 12$  的比特图
  - g) 全连接层 Output: 共有 10 个节点，分别代表数字 0 到 9，如果节点  $i$  的输出值为 0，则网络识别的结果是数字  $i$ 。
- 3) 训练过程:
- a) 前向计算: 从样本集中取一个样本  $(X, Y)$ ，将  $X$  输入网络，计算对应的输出。
  - b) BP: 计算实际输出与理想输出  $Y$  的差，按极小化误差的方法调整权重矩阵。
  - c) 可以自己定义训练阶段的个数 (epochs)，在每个阶段训练之后，会对 validation 数据集进行一次识别，以验证训练的成果。
2. 用 python 调用 tensorflow 进行网络的搭建:
- 1) Lenet 类的定义，网络结构的构建，loss 等的定义都在类的初始化函数中完成:

```

1 # importing packages
2
3 import tensorflow as tf
4 from tensorflow.contrib.layers import flatten
5 from sklearn.utils import shuffle
6 from tqdm import tqdm, trange
7
8 # define class ChenRJ_lenet5
9
10 class ChenRJ_lenet5():
11
12     # initial
13     def __init__(self, training_data, training_label, testing_data, testing_label, validation_data=None,
14                  validation_label=None, mean=0, stddev=0.3, learning_rate=0.001):
15
16         # training data
17         self.training_data = training_data
18         self.training_label = training_label
19
20         # assert if input data does not match requirement
21         assert (len(self.training_data) == len(self.training_label))
22         assert (self.training_data[0].shape[0] == 32 and self.training_data[0].shape[1] == 32)
23
24         # testing data
25         self.testing_data = testing_data
26         self.testing_label = testing_label
27
28         # assert if input data does not match requirement
29         assert (len(self.testing_data) == len(self.testing_label))
30         assert (self.testing_data[0].shape[0] == 32 and self.testing_data[0].shape[1] == 32)
31
32         # validation data
33         self.validation_data = validation_data
34         self.validation_label = validation_label
35
36         # assert if input data does not match requirement
37         assert (len(self.validation_data) == len(self.validation_label))
38         assert (self.validation_data[0].shape[0] == 32 and self.validation_data[0].shape[1] == 32)
39
40         # set number for outputs
41         self.output_num = 10
42
43
44         self.X = tf.placeholder(tf.float32, shape=(None, 32, 32, 1))
45         self.Y = tf.placeholder(tf.int32, shape=(None, self.output_num))
46
47         # parameter for kernels
48         self.mul = mean
49         self.sigma = stddev
50
51         # network setting
52
53         # Layer 1: Input 32x32x1, Output 28x28x6
54         self.conv1_kernels = tf.Variable(tf.truncated_normal(shape=[5, 5, 1, 6], mean=self.mul, stddev=self.sigma))
55         self.conv1_biases = tf.get_variable(name="conv1_biases", shape=[6],
56                                           initializer=tf.random_normal_initializer(stddev=0.3))
57         self.conv1 = tf.nn.conv2d(self.X, self.conv1_kernels, [1, 1, 1, 1], padding='VALID') + self.conv1_biases
58
59         # Pooling -> from 28x28 to 14x14
60         self.pool1 = tf.nn.max_pool(self.conv1, [1, 2, 2, 1], strides=[1, 2, 2, 1], padding='VALID')
61         # Activation
62         self.conv1 = tf.nn.relu(self.pool1)
63
64         # Layer 2: Input 14x14x6, Output 10x10x16
65         self.conv2_kernels = tf.Variable(tf.truncated_normal(shape=[5, 5, 6, 16], mean=self.mul, stddev=self.sigma))
66         self.conv2_biases = tf.get_variable(name="conv2_biases", shape=[16],
67                                           initializer=tf.random_normal_initializer(stddev=self.sigma))
68         self.conv2 = tf.nn.conv2d(self.conv1, self.conv2_kernels, [1, 1, 1, 1], padding='VALID') + self.conv2_biases
69
70         # Pooling -> from 10x10x16 to 5x5x16
71         self.pool2 = tf.nn.max_pool(self.conv2, [1, 2, 2, 1], strides=[1, 2, 2, 1], padding='VALID')
72
73         # Activation 2
74         self.conv2 = tf.nn.relu(self.pool2)
75
76         # Flatten -> from 5x5x16 to 400x1
77         self.flattened = flatten(self.conv2)
78
79         # Fully Connected Layer n.1
80         self.fc1_weights = tf.Variable(tf.truncated_normal(shape=[400, 120], mean=self.mul, stddev=self.sigma))
81         self.fc1_biases = tf.get_variable(name="fc1_biases", shape=[120],
82                                           initializer=tf.random_normal_initializer(stddev=self.sigma))
83         self.fc1 = tf.matmul(self.flattened, self.fc1_weights) + self.fc1_biases

```

```

83     # Activation 3
84     self.fc11 = tf.nn.relu(self.fc11)
85
86     # Fully Connected Layer n.2
87     self.fc12_weights = tf.Variable(tf.truncated_normal(shape=[120, 84], mean=self.mul, stddev=self.sigma))
88     self.fc12_biases = tf.get_variable(name="fc2_biases", shape=[84],
89                                       initializer=tf.random_normal_initializer(stddev=self.sigma))
90     self.fc12 = tf.matmul(self.fc11, self.fc12_weights) + self.fc12_biases
91     # Activation 4
92     self.fc12 = tf.nn.relu(self.fc12)
93
94     # Fully Connected Layer n.3
95     self.fc13_weights = tf.Variable(tf.truncated_normal(shape=[84, 10], mean=self.mul, stddev=self.sigma))
96     self.fc13_biases = tf.get_variable(name="fc3_biases", shape=[10],
97                                       initializer=tf.random_normal_initializer(stddev=self.sigma))
98     self.logits = tf.matmul(self.fc12, self.fc13_weights) + self.fc13_biases
99
100    # Loss and metrics
101    self.cross_entropy = tf.nn.softmax_cross_entropy_with_logits_v2(logits=self.logits, labels=self.Y)
102    self.loss_op = tf.reduce_mean(self.cross_entropy)
103    self.optimizer = tf.train.AdamOptimizer(learning_rate=learning_rate)
104    self.training_step = self.optimizer.minimize(self.loss_op)
105
106    self.correct_prediction = tf.equal(tf.argmax(self.logits, 1), tf.argmax(self.Y, 1))
107    self.accuracy_operation = tf.reduce_mean(tf.cast(self.correct_prediction, tf.float32))

```

## 2) 训练函数:

```

110 def train(self, epochs, batch_size):
111     assert (epochs > 0 and batch_size > 0)
112
113     num_examples = len(self.training_data)
114
115     print('Training . . .')
116
117     with tf.Session() as session:
118         session.run(tf.global_variables_initializer())
119         total_steps = trange(epochs)
120         for epoch in total_steps:
121             self.training_data, self.training_label = shuffle(self.training_data, self.training_label)
122             for offset in range(0, num_examples, batch_size):
123                 end = offset + batch_size
124                 X_batch, y_batch = self.training_data[offset:end], self.training_label[offset:end]
125
126                 _, acc, cross = session.run([self.training_step, self.accuracy_operation, self.cross_entropy],
127                                           feed_dict={self.X: X_batch, self.Y: y_batch})
128
129                 if self.validation_data.any() != None:
130                     validation_accuracy = self.evaluate(self.validation_data, self.validation_label, batch_size)
131                     total_steps.set_description(
132                         "Epoch {}th - validation accuracy {:.3f}".format(epoch + 1, validation_accuracy))
133
134                     total_steps.set_description(
135                         "Epoch {}th - validation accuracy {:.3f}".format(epoch + 1, validation_accuracy))
136
137             test_accuracy = self.evaluate(self.testing_data, self.testing_label, batch_size=batch_size)
138             return test_accuracy

```

## 3) 识别函数:

```

141 def evaluate(self, X_data, y_data, batch_size):
142     examples = len(X_data)
143     total_accuracy = 0
144     sess = tf.get_default_session()
145     for offset in range(0, examples, batch_size):
146         batch_x, batch_y = X_data[offset:offset + batch_size], y_data[offset:offset + batch_size]
147         accuracy = sess.run(self.accuracy_operation, feed_dict={self.X: batch_x, self.Y: batch_y})
148         total_accuracy += (accuracy * len(batch_x))
149     return total_accuracy / examples

```

## 3. 调用 tensorflow 的函数读取 MNIST 数据集:

```

11 # read data from mnist
12 mnist_data = input_data.read_data_sets("MNIST_data/", reshape=False, one_hot=True)
13
14 # classify data using module in tensorflow
15
16 # training data
17 train_X, train_Y = mnist_data.train.images, mnist_data.train.labels
18
19 # data for validating the trained network
20 validation_X, validation_Y = mnist_data.validation.images, mnist_data.validation.labels
21
22 # data for testing
23 test_X, test_Y = mnist_data.test.images, mnist_data.test.labels

```

## 4. 将自己手写的数字制作成可以被调用的形式。

```

28 # Testing my own hand_script
29 My_Hand_Script = np.zeros((100,28,28,1))
30
31 My_Label = np.zeros((100,10))
32
33
34 for i in range(10):
35     for j in range(10):
36         # path for my own handscript
37         filename = '/Users/chenrj/Desktop/my_handscript2/' + str(i) + '/' + str(j) + '.jpg'
38         # read images
39         image = cv2.imread(filename, cv2.IMREAD_GRAYSCALE)
40         # image reshape to [28,28,1] to match the requirement of dataset
41         image = np.array(image).reshape(28,28,1)
42         # add new image to my data set
43         My_Hand_Script[i*10+j]=image
44         # label my data set
45         My_Label[i*10+j][i]=1

```

## 5. 训练以及得到准确率。

```

56 # Lenet-5 initialing and training
57 my_lenet_network = ChenRJ_lenet5(train_X, train_Y, My_Hand_Script, My_Label, validation_X, validation_Y)
58
59 # Testing and show the quality of the network
60 accuracy = my_lenet_network.train(epochs=10,batch_size=100)
61 print("Accuracy on mnist test set: {:.3f}".format(accuracy))

```

## 四、 实验结果与分析：

### 1. MNIST 测试数据的识别率：97.9%。

```

Input image shape: (28, 28, 1)
Size of training set: 55000
Size of validation set: 5000
Size of test set: 10000
Training the model . . .
2019-01-09 23:43:31.827167: I tensorflow/core/platform/cpu_feature_guard.cc:141] Your CPU supports instructions that this TensorF
low binary was not compiled to use: AVX2 FMA
Epoch 10 - validation accuracy 0.982 : 100%|██████████| 10/10 [01:55<00:00, 12.12s/it]
Accuracy on MNIST test set: 0.979

```

### 2. 自己手写的数字：一开始识别率比较低（40%左右）。

```

Instructions for updating:
Please use alternatives such as official/mnist/dataset.py from tensorflow/models.
Input image shape: (28, 28, 1)
Size of training set: 55000
Size of validation set: 5000
Size of test set: 10000
Training the model . . .
Epoch 10 - validation accuracy 0.973 : 100%|██████████| 10/10 [02:02<00:00, 12.34s/it]
Accuracy on my own test set: 0.400

```

对比自己手写的数字跟 MNIST 数据集的数字之后，发现 0，2，5 和 9 这四个数字由于书写习惯的问题差别很大，导致了识别率比较低，因此重新进行了书写。

然后再观察写出来的数字，发现有断开或者笔画不连续的问题，因此再对手写的原始数据进行一定的预处理（膨胀操作等），最终使用的数据集贴在下面，识别率为 81%。由于书写习惯不同，还是存在一定的误差率，认为是正常的现象。

```
Input image shape: (28, 28, 1)
Size of training set: 55000
Size of validation set: 5000
Size of test set: 10000
Training the model . . .
2019-01-10 11:02:06.205326: I tensorflow/core/platform/cpu_feature_guard.cc:141] Your CPU supports instructions that this TensorFlow binary was not compiled to use: AVX2 FMA
Epoch 10 - validation accuracy 0.952 : 100% | 10/10 [01:54<00:00, 11.59s/it]
Accuracy on my own test set: 0.810
```

0 0 0 0 0 0 0 0 0 0

1 1 1 1 1 1 1 1 1 1

2 2 2 2 2 2 2 2 2 2

3 3 3 3 3 3 3 3 3 3

4 4 4 4 4 4 4 4 4 4

5 5 5 5 5 5 5 5 5 5

6 6 6 6 6 6 6 6 6 6

7 7 7 7 7 7 7 7 7 7

8 8 8 8 8 8 8 8 8 8

9 9 9 9 9 9 9 9 9 9

- 在测试的过程中发现，实现结果有一定的随机性，比如 MNIST 的测试数据集，在 97.5%到 98.5%之间波动。自己的数据集会在 80%左右波动。  
思考之后认为是在参数优化的过程中（下降法等），优化方式带有一定的随机性导致的。

- 在运行的过程中，存在这样的一个警告：

```
Training the model . . .
2019-01-10 10:58:57.310041: I tensorflow/core/platform/cpu_feature_guard.cc:141] Your CPU supports instructions that this TensorFlow binary was not compiled to use: AVX2 FMA
```



查询资料之后，发现是可以调用 CPU 的 AVX2，FMA 提高训练速度，应用以下代码调用：

```
import os
os.environ['TF_CPP_MIN_LOG_LEVEL'] = '2'
```

调用之后，训练速度提高了，但是发现识别率明显降低，因此没有使用这种方法。

## 五、 结论与心得体会

在这一次的实验中，我实现了一个基础的 CNN：Lenet5。做了多组实验，实现效果比较好。

在本学期的课程中，我们学习了理论知识，也进行了很多代码的实现，能够用自己的代码实现一些很好玩的东西，确实是一件令人兴奋的事情，特别感谢老师和助教老师的辛苦付出！